



Nuevos paradigmas de Base de Datos

Taller De ETL Con Mongodb Y Python

1. Introducción

Este taller se divide en las siguientes secciones:

- MongoDB en Docker (ya está disponible en el puerto 27017 según la guía previa).
- Python (utilizando pymongo y pandas).
- Dataset de ejemplo (sample_supplies, incluido previamente con MongoDB).
- Uso de Visual Studio Code como entorno de desarrollo.
- Actividades de Extracción, Transformación y Carga (ETL).
-

2. Objetivo del Taller


Aprender a:

- Conectarse a una base de datos MongoDB desde Python.
- Consultar y extraer datos de MongoDB.
- Transformar los datos utilizando pandas.
- (Opcional) Guardar los datos transformados o cargarlos en otra base de datos.



3. Estructura Sugerida del Proyecto

En la siguiente imagen se muestra donde deben quedar los archivos para ejecutar el ETL.



4. Preparar el Entorno MongoDB

Paso 1: Verificar que el contenedor MongoDB esté corriendo

Ejecuta en terminal:

```
docker ps
```

```
PS C:\Users\Administrador\Documents\GitHub\paradigmas> docker ps
CONTAINER ID   IMAGE                                COMMAND                  CREATED        STATUS        PORTS                               NAMES
86f7d542de3e   mysql:8.0                                           "docker-entrypoint.s..." 48 minutes ago Up 48 minutes 33060/tcp, 0.0.0.0:3310->3306/tcp   paradigmas-mysql-1
84655672df22   apache/airflow:2.8.1-python3.11   "/usr/bin/dumb-init ..." 48 minutes ago Up 48 minutes 0.0.0.0:8080->8080/tcp            airflow
878cb91daf30   mongo:6.0                                           "docker-entrypoint.s..." 48 minutes ago Up 48 minutes 0.0.0.0:27017->27017/tcp          paradigmas-mongodb-1
```

Si ves el contenedor paradigm-mongodb-1 en la lista, entonces está corriendo correctamente.

Paso 2: Descargar y guardar archivo JS dentro del contenedor

Guarda el contenido que mostraste como papelaria.js en la carpeta tmp del Docker, no en tu águina local:

<https://raw.githubusercontent.com/adiac/a/bigdata/refs/heads/master/papelaria.js>

En la sección del Shell de la imagen que está corriendo, ejecuta todos los pasados abajo para que descarguemos el archivo usando wget

```
>docker exec -it paradigmas-mongodb-1 bash
>cat /etc/os-release
>apt update
>apt install wget
>cd tmp
>wget
https://raw.githubusercontent.com/adiac/a/bigdata/refs/heads/master/papeleria.js
>cd ..
```

5. Cargar el archivo JSON en MongoDB

Usa mongosh desde el contenedor para ejecutar el archivo:

```
mongosh /tmp/papeleria.js
```

Inicia mongo desde el contenedor:

```
mongosh
```

```
root@878cb91daf30:/# mongosh
Current Mongosh Log ID: 67fd4d5ffe0061d2ced861df
Connecting to:      mongodb://127.0.0.1:27017/?directConnection=true&serverSelectionTimeoutMS=2000&appName=mongosh+2.5.0
Using MongoDB:      6.0.21
Using Mongosh:       2.5.0

For mongosh info see: https://www.mongodb.com/docs/mongodb-shell/
```

Usar la base de datos

Dentro de mongosh, asegúrate de estar en la base de datos papeleria:

```
use papeleria
```

```
test> use papeleria
switched to db papeleria
papeleria> |
```

Verificar que los datos se insertaron correctamente:

Puedes verificarlo con:

```
db.inventario.find().pretty()
```

6. Ejemplos de Consultas

- Mostrar todos los ítems disponibles

```
db.inventario.find({}, { item: 1, qty: 1, _id: 0 })
```

- Buscar productos con estado: "A"

```
db.inventario.find({ estado: "A" })
```

- Buscar productos con más de 20 de qty

```
db.inventario.find({ qty: { $gt: 20 } })
```

- Productos que tengan color "azul"

```
db.inventario.find({ color: "azul" })
```

- Productos en la ciudad de "Lima"

```
db.inventario.find({ ciudad: "Lima" })
```


7. Preparar el Entorno Python

Crear archivo ".env" (con el punto)

Crea un archivo llamado .env dentro de la carpeta mongodb del proyecto con el siguiente contenido:

```
MONGO_URI=mongodb://localhost:27017  
DB_NAME=papeleria  
COLLECTION=inventario
```

O lo puede descargar de este [enlace](#).



```
EXPLORER
PARADISGMAS
  > .venv
  > airflow
  > datos
  > mongodb
  > .env

mongodb > .env
1 MONGO_URI=mongodb://localhost:27017
2 DB_NAME=papeleria
3 COLLECTION=inventario
```

8. Crear Script ETL Básico

Fases del ETL

Fase	Acción
Extract	Conecta a la base papeleria, colección inventario
Transform	Convierte en DataFrame, limpia, calcula precio_total, agrupa por ciudad
Load	Guarda el resumen en un archivo CSV llamado productos.csv

9. Descargar y Ejecutar el Notebook ETL


1. Descargar el notebook al proyecto en la máquina local:

<https://raw.githubusercontent.com/adiac/a/basededatosETL/refs/heads/main/mongodb/etl.ipynb>

1. copiarlo en la carpeta mongodb del proyecto.
2. Abrirlo con Visual Studio Code.
3. Ejecutar celda por celda. Puede que te solicite seleccionar un entorno (environment).

Asegúrate de tener instalado ipykernel para Jupyter:

```
pip install ipykernel
```



Paso 4: Ejecutar el ETL

Recuerda ejecutar fila por fila ya que es un cuaderno de Jupyter y analice cada una de las instrucciones realizadas y es posible que te pregunte nuevamente el enviroment.

